

SAVI 实验汇报

汇报人：王振坤

2026年8月12日

目录

CONTENTS

01 | MuSR实验

02 | Belief-R实验

03 | 未来规划

问题

模型推理是**一步步往下写**的，即使中间某一步有歧义，也必须选择一步往下走，等线索出现时，前面已经走错的步骤无法修正（commit failure）。——**采样方法**（Greedy）
例子：If Bob is going fishing by the bank, how likely is it that there will be an ATM?

SAVI 换一种写法：**让几种可能的中间状态先并存、下一步的候选也从「采样几乎写不出来」的地方取一些、到最后再一次性挑出整条最好的**。这样它能得到「一步步写、多写几遍挑一条」**永远得不到的正确解**。
——**全局解码**（Global）

support & scoring

在Countdown任务上，找不到can't → can，且不是real-problem任务




图1：Countdown任务过程示意

实验目的

1. 说明 commit failure 问题在真实基础准上存在
2. 检验全局解码能否实现can't → can
3. 归因定位：找出全局解码真正起作用的部分

□ MuSR 介绍 (object_placement)

真实的信念追踪(belief tracking)基准: 长叙事里物体被移动多次, **每次只有部分角色看见**; 问「角色 X 认为物体 Y 在哪 / 会去哪找」, 多选题

■ 实际的例子

Ann 把钥匙放进**抽屉**后出门; 她不在时Ben 挪到**盒子**。Ann 会去哪找?——**抽屉**(她没看见挪动)。模型顺着最近提到的「盒子」写下去, 就回不了头。

■ 为什么选择这个数据集

- **状态可枚举**: 维护一个信念状态表, (观察者, {物品: 位置})。
- **答案可以直接读出**: 排除了“知道但用不对”的情况。
- **没有免费^[1]的验证器**: 不像countdown一样有可执行检查器能够给出100%正确的答案, 使用多数投票作为公平基线。

■ 主要实验配置

Qwen3-4B; 采样温度T=1.0, N最大1024

[1] “免费”：不需要训练/学习；不需要事实/人工标注；任务本身可机械计算




图2: the certification funnel

- **F1 budget escalation**: 在不同的N下保持出错的题目107@N=32 → 105@N=1024。
- **F2 four checks**: (i)统计稳定(ii)给定真实事实下能做对(iii)不同模型规模下保持出错(iv)不同seed重现。
- **F3 self-extract**: 添加prompt, 让模型先提取叙事内容, 然后再进行判断。
- **F4 template**: 在结构化模板 (按照事件顺序列出信念列表) 下重新运行验证。

最终19道测试题: 15 (采样到了、投票投错) +4 (1024次采样一次都没包含)

知识对照3道: F2中剔除的46道知识对照题目中抽取3道, 作为对照 (如果答对说明泄露了答案)

这19道题是不是“罕见”的?

流行率: 总共有40道题符合判定标准, 其中有80%的题目存在**全票错误** (所有链都走向相同的错误步骤)。说明分支错误率高的不是该19道题独有的。

问题：是不是改进挑选策略，就能从已经写出的完整链条中挑出正确答案？
——三个实验逐步加强，但都失败

- 两种加强方式都基于结构化prompt的模型输出（步级别链条）：
- **learned-verifier**：训练一个步级事实一致性探针，对步骤节点跨链打分，取得分最高链。
 - **gold-facts mask**：跨链条归并成**trellis**，掩码禁用矛盾节点，最优答案允许跨链拼接。（合并率 > 0.9）

池内聚合方式	fixed / 19	备注
majority voting	0	主基线
learned-verifier rerank (= best-of- <i>N</i>)	净 +2, CI [0, 5]	与 0 不可分;逐题与 BoN 相等
gold-facts mask (oracle), sampled chains only	3	全在已有链内; 跨链拼接 0

表1：采样的不同选取方式结果

- **trellis结构本身无增量**：learned-verifier = 对完整链条打分的 Best of N
- 跨链拼接机制没有起到作用，只在完整的采样链中选

缺的不是挑选方式——缺的东西不在当前的pool中

询问模板 prefix+target

prefix:

[叙事全文] + [问题 + 选项]


[信念状态 t-1] BELIEF[t-1]: {"Ben": {"keys": "drawer"}, ...}

[event t] “the keys are moved to the box.”

{本轮的信念状态是什么? }

target:

[枚举可达状态] BELIEF[t]: {"Ben": {"keys": "box"}, ...}



实验结果

- 增益主要来源**不是枚举**，而是event事实句
- model-written是**修复增益最高**的方式（4→9），尽管模型写入的内容大部分是不正确的——“**分布坍塌**”比“**塌向哪里**”重要
- 句子质量和是否能够修正的相关性弱（Spearman 0.31），修复的6道题全部来自不精确的event
- 增益**不来自新信息**，来自解码方式本身。——信息“利用率”

	fixed / 19	+ gold mask (ceiling)	事件句备注
majority voting	0	—	—
learned-verifier rerank (= best-of- <i>N</i>)	净 +2(CI [0, 5])	3	—
<i>enumerated states + likelihood, per-step event sentence:</i>			
none	3	5	整行删掉
placeholder (no content)	4	6	固定占位句, 零事实内容
model-written (no human-labeled input)	9	12	模型自己从叙事提取; 解析错了 不剔除 , 错就错着用
gold	10	15	来自金标注释

表2: SAVI实验结果

目录

CONTENTS

01 | MuSR实验

02 | Belief-R实验

03 | 未来规划

Belief-R

「补一句话之后,原结论要不要收回」的信念修正benchmark

测试样本举例

γ1 **If** John reads a book, **then** John learns something new
γ2 John reads a book
γ3 **If** Jessica explains quantum physics to John for the first time, **then** John learns something new

(a) John learns something new
(b) John does not learn something new
(c) John may or may not learn something new

标注一致度	场景数	题目数	BU (REQ)	BM (ALT)
lv=5(5/5)	391	782	257	134
lv=4(4/5)	479	958	278	201
lv=6(异常, 排除)	2	4	2	0
合计	872	1,744	537	335

表3：数据集构成总览

逻辑语言描述

γ1 $p \rightarrow q$ 称 $p \wedge r \rightarrow q$ 为REQ (必要的)
γ2 p 称 $p \vee r \rightarrow q$ 为ALT (可替换的)
γ3 $r \rightarrow q$

为什么这能测"信念"

若是REQ情况, 补充上 γ3 说明只有 γ1 不够—**Belief-Update**
若是ALT 情况, 补充上 γ3 什么都不用改—**Belief-Maintaining**
——"新信息到来后维持还是撤回"的信念修正问题,答案由模型对说话人意图的把握决定。

每个场景 ponens: γ2 给的是 p, 问的是 q
两个问题 tollens: γ2 给定是~q, 问的是 p

模型自身无法解答

sample方法在三种提示下 (DP/CoT/PS) 采样 N=32 条链, BU类题目中, 91.3%-95.7%的题目一次都没有写出正确答案

模型	BU-pon	BU-tol	BM-pon	BM-tol	BREU
Qwen3-4B	0.004	0.019	0.978	0.970	0.493
Qwen2.5-7B	0.128	0.054	0.836	0.948	0.492
少样本示范	-	-	-	-	增益 ≈0

表4: 模型直接作答结果

两步骤求解

① 判断条件关系

将条件关系分成两类:
BU(REQ) (必要) : $p \wedge r \rightarrow q$
BM(ALT) (替代) : $p \vee r \rightarrow q$



使用oracle生成的模板

BU修复
pon 0.006 → 0.994; toll 0.024 → 0.838
BM 无损伤(0.976 → 0.997)

问题聚焦到关系判断

② 根据条件生成输入模板

- 判断 = REQ → 前提改写成 and 型:
- ① The fact that John reads a book does not by itself bring it about that John learns something new; *that happens only if* in addition Jessica explains quantum physics to John for the first time.
 - ② John reads a book
- 判断 = ALT → 前提改写成 or 型:
- ① The fact that John reads a book by itself brings it about that John learns something new; *and* the fact that Jessica explains quantum physics to John for the first time by itself also brings it about that John learns something new.
 - ② John reads a book

模型现成行为无法判断条件关系

路线	具体实现	结果
零样本推断	判断 γ_1 和 γ_3 的关系	0.519(bal-acc)
枚举 + 似然打分	两读法各写成一句接同一前缀比似然	0.526(AUC)→0.503(bal-acc)
上下文内显式选择	两读法并列写进提示, 带推理空间二选一	0.520(bal-acc)
NLI 蕴含模型	只看文本比固守度	0.550–0.562(AUC)→0.532(bal-acc)

表5：现成行为结果

NLI蕴含模型	$s(p \models q) = \text{NLI}(\text{"}p\text{"蕴含" }q\text{"的概率})$ $s(r \models q) = \text{NLI}(\text{"}r\text{"蕴含" }q\text{"的概率})$ $\Delta = s(r \models q) - s(p \models q)$	→ 原条件 p 单独把结果推出有多牢靠 → γ_3 的新条件 r 单独推出结果有多可靠 → 哪一个联系更加牢靠
---------	--	--

问题

判断答案在行为中无法获得，在表征中能否找到

探针结构

单线性层，逻辑回归执行二分类任务（尽可能降低探针容量对于实验结果的影响）

模型	bal-acc [CI]	SM [CI]	高出词面
Qwen3-4B	0.706 [0.658,0.753]	0.624 [0.554,0.691]	✓
Qwen2.5-7B	0.718 [0.673,0.761]	0.635 [0.570,0.701]	✓
Llama-8B	0.709 [0.657,0.755]	0.601 [0.541,0.659]	✓

词面对照

使用词袋分类器，输入的为题面文本，二分类
bal-acc→0.556， SM-acc→0.528

SM长度配平子集（防止仅依靠句长判断）

将 $\Delta = y_3 - y_1$ 字符差按照15为梯度进行分箱，保证每箱中REQ/ALT数量相同，使得句长无法提供标签信息，以CI区间高于词面对照SM-acc 0.528作为判据。

$$P(\text{Label} = \text{REQ} \mid \Delta \text{落在某箱}) = P(\text{Label} = \text{ALT} \mid \Delta \text{落在某箱}) = 0.5$$




图 2：准确率-探针位置

表征层能够读出信号

问题

最后一个隐藏层上的探针仍有信号 (0.688) → 仅微调投影层能否修复

两种微调方式

- B4 (仅投影层)
- B3 (全部隐层, 不含投影层)
- B3L、B4L为预算扩大实验组

- 修复投影层有提升(0.519→0.631), 说明目标方向存在, 但修复不满(0.631 vs 0.688)
- 全隐层微调追平探针(0.713 vs 0.692), 说明隐藏层内可修复的余量更多




图 3 : 各种方法的条件关系判断准确率

- **模型有能力做对这类 “Beflief” 问题，但用不对。**
 - **给 support 轴和 socring 轴提供支撑。**多数投票和 Best-of-N 无从下手——候选池中找不到答案。改成“枚举 + 打分”的方式能够修复。
 - **没有对多步解码策略的支持。**数据集样本推理深度为2，第二步是确定性的，全局解码、多步累积等在此派不上用场。
-

问题与计划

- 在 “belief” 问题上，能够找到一种方式“修复”，增益的来源是信息的利用方式，但这里的利用方式目前对应着不同的模板——仍然不是依靠模型自身来修复这类问题
- LLM-as-a-Verifier 的结合
- 其他 benchmark 的扩展

感谢观看！

汇报人：王振坤

2026年8月12日